

Grafo de Conocimiento Académico con GraphRAG

Una réplica académica a escala reducida del People Knowledge Graph de NASA,
construida con Neo4j, OpenAlex y Google Gemini

Maestría en Big Data y Ciencia de Datos

Proyecto académico — 2026

1. Introducción y motivación

Este proyecto replica, a escala académica, la iniciativa "People Knowledge Graph" desarrollada por el equipo de People Analytics de NASA, presentada públicamente en un community call organizado por Memgraph en abril de 2025. En dicha iniciativa, NASA construyó un grafo de conocimiento que conecta empleados, proyectos y habilidades para identificar expertos internos, detectar proyectos similares y responder preguntas organizacionales mediante un chatbot basado en GraphRAG (Graph Retrieval-Augmented Generation).

Dado que no se contaba con datos propios de una organización, se optó por construir un grafo análogo utilizando datos públicos y reales extraídos de OpenAlex, un índice académico abierto y gratuito. El dominio elegido para la búsqueda fue "inteligencia artificial aplicada a la exploración espacial", buscando mantener un paralelismo temático con el caso original de NASA.

El objetivo del proyecto no es realizar un estudio bibliométrico riguroso sobre exploración espacial, sino aprender de forma práctica el diseño de un grafo de conocimiento orientado a nodos en Neo4j y la implementación de un pipeline GraphRAG completo, incluyendo sus capacidades y limitaciones reales.

1.1 Objetivos

- Diseñar e implementar un grafo de conocimiento en Neo4j a partir de datos públicos reales.
- Replicar el patrón de modelado de NASA: nodos Person, Project y Skill, todos indexables bajo una etiqueta común (Entity).
- Calcular relaciones de similitud semántica entre proyectos mediante embeddings, análogo al uso de cosine similarity de NASA.
- Construir un pipeline GraphRAG funcional, combinando búsqueda vectorial y expansión de grafo con un LLM gratuito (Google Gemini).
- Evaluar críticamente las capacidades y limitaciones del sistema frente a distintos tipos de preguntas.

2. Marco conceptual

Antes de describir la metodología, se introducen brevemente los conceptos técnicos centrales sobre los que se apoya este proyecto.

2.1 Embeddings

Un embedding es una representación numérica de un texto (una palabra, una oración, un párrafo) en forma de vector de N dimensiones, generada por un modelo de lenguaje entrenado para capturar el significado semántico del contenido. Dos textos con significados similares producen vectores cercanos entre sí en ese espacio N-dimensional, mientras que textos de significado distinto producen vectores alejados. Esta propiedad permite comparar textos por significado mediante operaciones matemáticas simples, como la similitud coseno, en lugar de comparar las palabras exactas que contienen.

En este proyecto se utilizó el modelo local y gratuito all-MiniLM-L6-v2 (sentence-transformers) para generar embeddings de 384 dimensiones a partir de los títulos y descripciones de los proyectos, y de las preguntas realizadas al chatbot.

2.2 Bases de datos NoSQL orientadas a grafos

Las bases de datos NoSQL ("Not Only SQL") son sistemas de almacenamiento que no utilizan el modelo relacional clásico de tablas, filas y columnas, sino estructuras alternativas mejor adaptadas a ciertos tipos de datos. Existen varias familias: documentales (MongoDB), clave-valor (Redis), columnares (Cassandra) y orientadas a grafos (Neo4j, Memgraph), utilizada en este proyecto.

En una base de datos orientada a grafos, la información se modela como nodos (entidades, por ejemplo Person o Project) y relaciones (conexiones con dirección y, opcionalmente, propiedades propias, por ejemplo WORKS_ON). A diferencia de una base relacional, donde vincular información de múltiples tablas requiere operaciones JOIN cuyo costo crece con la profundidad de la consulta, en un grafo las relaciones están almacenadas físicamente junto a los nodos que conectan. Esto permite recorrer caminos de múltiples saltos (por ejemplo, persona → proyecto → habilidad → otro proyecto) con un rendimiento prácticamente constante, independiente de la cantidad total de datos almacenados. Esta característica es la que hace a Neo4j especialmente adecuado para preguntas del tipo "¿quién tiene experiencia relacionada con X?", que en SQL requerirían múltiples JOIN costosos.

2.3 RAG (Retrieval-Augmented Generation)

RAG es una técnica que combina un modelo de lenguaje (LLM) con una fuente de datos externa, con el objetivo de que el modelo responda basándose en información verificable en lugar de depender únicamente de lo aprendido durante su entrenamiento. El flujo típico de RAG es:

- 1. La pregunta del usuario se convierte en un embedding.
- 2. Se busca en una base de datos vectorial los fragmentos de texto (documentos, párrafos) cuyo embedding sea más similar al de la pregunta.
- 3. Esos fragmentos se incluyen como contexto en el prompt enviado al LLM.
- 4. El LLM redacta una respuesta basada en ese contexto, reduciendo el riesgo de que invente información (alucinaciones).

El RAG tradicional recupera fragmentos de texto planos e independientes entre sí (por ejemplo, párrafos de distintos documentos), sin ninguna noción de cómo esos fragmentos se relacionan entre ellos.

2.4 GraphRAG

GraphRAG extiende el enfoque anterior reemplazando (o complementando) la base de datos vectorial de texto plano por un grafo de conocimiento. En lugar de recuperar fragmentos de texto aislados, el sistema recupera nodos relevantes del grafo y luego expande la búsqueda recorriendo sus relaciones directas, obteniendo "tripletas de contexto" (nodo – relación – nodo) que describen no solo el contenido de cada entidad, sino también cómo se conecta con otras. Es el enfoque que utiliza NASA en su People Knowledge Graph, y el que se implementó en este proyecto: la búsqueda vectorial identifica los proyectos más relevantes semánticamente a la pregunta, y luego el grafo se expande un salto para incorporar las personas, habilidades, revistas y proyectos relacionados antes de generar la respuesta final.

2.5 ¿Por qué GraphRAG en lugar de RAG tradicional?

La diferencia central entre ambos enfoques es que el RAG tradicional responde bien preguntas sobre el contenido de un documento aislado, pero no puede responder preguntas que dependen de relaciones entre distintas entidades, ya que no tiene forma de representar ni recorrer esas conexiones. GraphRAG sí puede, porque la estructura de relaciones es parte constitutiva de los propios datos, no algo que deba inferirse del texto.

Ejemplos concretos observados en este proyecto que ilustran esta diferencia:


- Un RAG tradicional sobre los 150 papers como documentos aislados podría responder qué dice un paper puntual sobre IA en salud, pero no podría identificar que dos papers distintos están conectados por una relación de cita (CITES) ni que dos personas colaboraron porque ambas trabajaron en el mismo proyecto (WORKS_ON).
- En el caso de la pregunta hipotética sobre un equipo de IA explicable aplicada a diagnóstico médico (sección 4.5.2), el sistema utilizó la relación CITES para identificar que un proyecto de oncología estaba citado directamente por el trabajo principal de XAI, y así fundamentar mejor la recomendación de personas a contactar. Esa conexión es estructural (existe en el grafo, no en el texto de un único documento) y por lo tanto invisible para un RAG tradicional basado solo en fragmentos de texto.

- En contrapartida, esta misma sección del informe (4.5.3) documenta que GraphRAG no resuelve automáticamente todos los problemas: preguntas de agregación sobre la totalidad del grafo ("¿quién participa en más proyectos?") siguen requiriendo consultas estructuradas directas (Cypher), ya que la búsqueda vectorial solo expone al modelo una porción local del grafo, no su totalidad.*

3.1 Fuente de datos

- Metadatos del trabajo (título, año, resumen reconstruido desde el índice invertido de OpenAlex).
- Autores (authorships), incluyendo su institución de afiliación cuando estaba disponible.
- Conceptos asociados (concepts), utilizados como proxy de habilidades (skills), filtrando aquellos con score de relevancia menor a 0.3.
- Fuente de publicación (primary_location.source), utilizada como nodo Venue.
- Referencias citadas (referenced_works), utilizadas para construir la relación CITES únicamente entre pares de trabajos que pertenecen ambos a la muestra de 150 papers.

El esquema resultante refleja el mismo principio de modelado que NASA describió en su presentación: todos los nodos, independientemente de su tipo específico, comparten además la etiqueta genérica *Entity*, lo que permite construir un único índice vectorial que cubre la totalidad del grafo.



Las entidades y relaciones del modelo son:

Nodo	Origen del dato	Propiedades principales
------	-----------------	-------------------------

Person	authorships.author	person_id, name
Project	work (paper)	project_id, title, year, description, embedding
Skill	concepts	skill_id, name
Organization	authorships.institutions	org_id, name
Venue	primary_location.source	venue_id, name

Relación	Desde → Hacia	Propiedad
WORKS ON	Person → Project	—
REQUIRES SKILL	Project → Skill	score
AFFILIATED WITH	Person → Organization	—
PUBLISHED IN	Project → Venue	—
CITES	Project → Project	—
SIMILAR TO	Project → Project	score (cosine similarity)

3.3 Carga de datos

La ingesta se realizó en dos etapas mediante scripts de Python. En la primera (01_fetch_data.py) se descargaron y transformaron los datos de OpenAlex a archivos CSV. En la segunda (02_load_neo4j.py) se cargaron a Neo4j mediante el driver oficial (bolt), utilizando sentencias MERGE en lotes de 500 registros para garantizar idempotencia y evitar duplicados, junto con constraints de unicidad sobre los identificadores de cada tipo de nodo.

3.4 Embeddings y similitud semántica

Siguiendo el mismo enfoque que NASA aplicó con cosine similarity entre descripciones de proyecto, se generaron embeddings de 384 dimensiones para cada nodo Project (a partir de título + descripción) utilizando el modelo local y gratuito all-MiniLM-L6-v2 (sentence-transformers). Se calculó la similitud coseno entre todos los pares de proyectos, creando la relación SIMILAR_TO para aquellos pares que superaron un umbral de 0.75. Adicionalmente, se creó un índice vectorial en Neo4j (entity_embeddings) sobre la etiqueta Entity, habilitando búsqueda semántica mediante db.index.vector.queryNodes.

3.5 Arquitectura del chatbot GraphRAG


El pipeline replica el flujo descrito por NASA en cuatro etapas:

- 1. La pregunta del usuario se convierte en un embedding con el mismo modelo utilizado para los proyectos.
- 2. Se ejecuta una búsqueda vectorial ("pivot search") sobre el índice de Neo4j, recuperando los K nodos Project más similares semánticamente a la pregunta.
- 3. Se expande el grafo un salto desde cada nodo relevante, recolectando las relaciones vecinas (personas, skills, venues, citas y similitudes) como "context triplets", en la misma terminología que emplea NASA.
- 4. Los triplets junto con la pregunta original se envían como contexto a un modelo de lenguaje (Google Gemini, vía Google AI Studio, plan gratuito), que redacta la respuesta final basándose exclusivamente en la información provista.

El parámetro TOP_K, que determina cuántos nodos trae la búsqueda vectorial inicial, resultó ser un factor determinante en el comportamiento del sistema, como se detalla en la sección de resultados y limitaciones.

4. Resultados

4.1 Volumen y composición del grafo



The screenshot shows a Neo4j Cypher query interface. The query is: `MATCH (n) UNWIND labels(n) AS tipo RETURN tipo, count(*) AS cantidad ORDER BY cantidad DESC`. The results are displayed in a table with two columns: 'tipo' and 'cantidad'. The table contains six rows of data, ordered by count in descending order.

tipo	cantidad
"Entity"	2358
"Person"	1016
"Organization"	585
"Skill"	490
"Project"	150
"Venue"	117

Started streaming 6 records after 10 ms and completed after 14 ms.

Figura 2. Conteo de nodos por tipo de etiqueta.

Entidad	Cantidad
Person	1016
Organization	585
Skill	490
Project	150
Venue	117
Total de nodos (Entity)	2358


En cuanto a relaciones, se cargaron 1043 WORKS_ON, 1314 REQUIRES_SKILL, 1490 AFFILIATED_WITH, 143 PUBLISHED_IN, 96 CITES y 13 SIMILAR_TO.



The screenshot shows a Neo4j Cypher query interface. The query is: `MATCH (p1:Project)-[:CITES]->(p2:Project) RETURN count(*) AS total_citas`. The results are displayed in a table with one column: 'total_citas'. The table contains one row of data.

total_citas
96

Figura 3. Verificación del total de relaciones CITES dentro de la muestra.




The screenshot shows a Neo4j Cypher query interface. The query is: `MATCH (p1:Project)-[:SIMILAR_TO]->(p2:Project) RETURN count(*) AS total_similares`. The results are displayed in a table with one column: 'total_similares'. The table contains one row of data.

total_similares
13

Figura 4. Verificación del total de relaciones SIMILAR_TO.

4.2 Distribución de cola larga en habilidades

Se observó una distribución de tipo long-tail (similar a la ley de Zipf) en la relación REQUIRES_SKILL: un número reducido de skills concentra la mayoría de las conexiones, mientras que la mayoría de los skills aparecen en uno o dos proyectos únicamente.



```
1 MATCH (s:Skill)-[:REQUIRES_SKILL]-(p:Project)
2 RETURN s.name, count(p) AS proyectos ORDER BY proyectos DESC LIMIT 10
```

	s.name	proyectos
1	"Computer science"	130
2	"Artificial intelligence"	106
3	"Data science"	49
4	"Machine learning"	30
5	"Knowledge management"	27
6	"Field (mathematics)"	24
7	"Management science"	22
8	"Applications of artificial intelligence"	17
9	"Deep learning"	15
10	"Engineering"	15

Started streaming 10 records after 49 ms and completed after 52 ms.

Figura 5. Ranking de las 10 skills más repetidas entre proyectos.

Este resultado también evidencia un sesgo de la muestra: dado que la búsqueda en OpenAlex se realizó por texto libre, los conceptos genéricos "Computer science" (130 proyectos) y "Artificial intelligence" (106 proyectos) dominan ampliamente, mientras que conceptos específicos aparecen con mucha menor frecuencia. Este fenómeno se retoma en la sección de limitaciones.

4.3 Validación de rankings estructurales

Se ejecutaron consultas Cypher de agregación directa para tener una referencia de verdad ("ground truth") contra la cual comparar las respuestas del chatbot GraphRAG.

```

1 MATCH (p:Person)-[:WORKS_ON]->(pr:Project)
2 RETURN p.name, count(pr) AS proyectos ORDER BY proyectos DESC LIMIT 5

```

	p.name	proyectos
1	"Francisco Herrera"	3
2	"Javier Del Ser"	3
3	"Tan Yiğitcanlar"	3
4	"Natalia Díaz-Rodríguez"	2
5	"Yogesh K. Dwivedi"	2

Figura 6. Personas con mayor cantidad de proyectos (consulta Cypher directa).

```

1 MATCH (v:Venue)<-[:PUBLISHED_IN]-(p:Project)
2 RETURN v.name, count(p) AS proyectos ORDER BY proyectos DESC LIMIT 5

```

	v.name	proyectos
1	"IEEE Access"	5
2	"Information Fusion"	4
3	"Nature Communications"	3
4	"Sustainability"	3
5	"Journal of Artificial General Intelligence"	2

Figura 7. Revistas y conferencias (Venue) con más publicaciones asociadas.

4.4 Visualización del grafo en Neo4j Bloom

Se utilizó Neo4j Bloom (incluido gratuitamente con la licencia de desarrollo Enterprise de Neo4j Desktop) para explorar visualmente el grafo, asignando un color distinto a cada tipo de nodo.




Figura 8. Vista general de Person (oliva) conectados a Project (cian) mediante WORKS_ON. Se observan claramente proyectos con distinto grado de colaboración.




Figura 9. Vista coloreada por tipo de nodo mostrando clusters temáticos (ej. Explainable AI) con sus autores y habilidades asociadas.

4.5 Casos de uso del chatbot GraphRAG

A continuación se presentan los resultados obtenidos al interrogar al chatbot, organizados según el tipo de pregunta.

4.5.1 Casos de éxito: preguntas temáticas

El sistema mostró un desempeño sólido ante preguntas de tipo temático/interpretativo, donde la búsqueda por similitud semántica es apropiada. La siguiente respuesta, ante la pregunta "¿Qué proyectos aplican inteligencia artificial en el ámbito de la salud o medicina?", ilustra el comportamiento esperado: el sistema recuperó proyectos, personas y habilidades reales, sin introducir información no presente en el grafo.

```
Received notification from DBMS server: <GqlStatusObject gql_status='01N01', status_description='warn: feature deprecated with replacement. db.index.vector.queryNodes is deprecated. It is replaced by SEARCH.', position=<SummaryInputPosition line=2, column=9, offset=9>, raw_classification='DEPRECATION', classification=<NotificationClassification.DEPRECATION : 'DEPRECATION', raw_severity='WARNING', severity=<NotificationSeverity.WARNING: 'WARNING', diagnostic_record={'classification': 'DEPRECATION', 'severity': 'WARNING', 'position': {'offset': 9, 'line': 2, 'column': 9}}, 'OPERATION': '', 'OPERATION_CODE': '0', 'CURRENT_SCHEMA': '/'> for query: "\n CALL db.index.vector.queryNodes('entity_embedding', $k, $embedding)\n YIELD node, score\n RETURN node.project_id AS project_id,\n labels(node) AS labels,\n e) AS name,\n score\n =\n (nodos relevantes encontrados: ['Generative artificial intelligence in innovation management: A preview of future research developments', 'Augmenting human innovation teams with artificial intelligence: Exploring transformer-based language models', 'Human resource management in the age of generative artificial intelligence: Perspectives and research directions on ChatGPT', 'Artificial intelligence and corporate innovation: A review and research agenda', 'Urban Artificial Intelligence: From Automation to Autonomy in the Smart City'])\n\nRespuesta:\nBasándonos en los datos del grafo, lo que más se investiga es la aplicación de la Inteligencia Artificial (IA / Artificial intelligence) -especialmente la IA generativa- en el ámbito de la gestión (management), la innovación y las ciencias de la computación.\n\nEsto se evidencia en los siguientes elementos del contexto:\n\n**Skills (habilidades) comunes:** Las habilidades más requeridas y compartidas entre los proyectos analizados son Artificial intelligence, Computer science y Knowledge management.  
**Proyectos clave:**  
* Generative artificial intelligence in innovation management: A preview of future research developments (donde trabajan Yogesh K. Dwivedi y Marcello M. Mariani).  
* Augmenting human innovation teams with artificial intelligence: Exploring transformer-based language models (donde trabajan Sebastian Gregor Bouschery, Vera Blažević y Frank T. Piller).  
* Human resource management in the age of generative artificial intelligence: Perspectives and research directions on ChatGPT (en el cual investigan autores como Pawan Budhwar, Soumyadeb Chowdhury y Geoffrey Wood, entre otros).  
  
Toda la red de relaciones apunta fuertemente a entender cómo la IA transforma la gestión del conocimiento, el desarrollo de nuevos productos y la gestión de recursos humanos.  
  
Pregunta> |
```

Figura 10. Respuesta del chatbot ante una pregunta temática, citando proyectos, autores y skills reales del grafo.

4.5.2 Casos destacados: búsqueda de talento para necesidades hipotéticas

Se plantearon preguntas hipotéticas simulando el caso de uso principal que motivó a NASA a construir su People Graph: encontrar expertos internos para necesidades organizacionales nuevas. Ante la pregunta "si tuviera que armar un equipo para desarrollar un nuevo combustible o propelente para cohetes espaciales, ¿qué personas del grafo tienen el perfil de habilidades más adecuado?", el sistema respondió de forma particularmente valiosa: reconoció explícitamente que no existían proyectos exactos sobre el tema, pero generalizó razonablemente hacia el perfil disponible más cercano (ciencia de materiales, nanotecnología, propiedades térmicas), agrupando personas reales por especialización.

Respuesta:
 Basándose estrictamente en la información del contexto proporcionado, no se mencionan proyectos o personas directamente relacionados con el desarrollo de "combustibles o propelentes para cohetes".

Sin embargo, para un equipo de este tipo, los perfiles más idóneos serían aquellos con habilidades avanzadas en **Ciencia de materiales (Materials science)**, **Nanotecnología (Nanotechnology)** e ingeniería aplicada al análisis de propiedades físicas y térmicas. Las personas del grafo con este perfil son:

1. Especialistas en diseño y ciencia de materiales avanzados
 Asociados al proyecto **Artificial intelligence and machine learning in design of mechanical materials** (que requiere las habilidades de **Materials science**, **Nanotechnology**, **Mechanical engineering** y **Mechanical design**):

- * **Kai Guo**
- * **Zhenze Yang**
- * **Chi-Hua Yu**
- * **Markus J. Buehler**

2. Especialistas en exploración de propiedades y conductividad térmica de materiales
 Asociados al proyecto **Accelerating materials-space exploration for thermal insulators by mapping materials properties via artificial intelligence** (que requiere habilidades en **Thermal conductivity** y **Machine learning**):

- * **Thomas A. R. Purcell**
- * **Matthias Scheffler**
- * **Luca M. Ghiringhelli**
- * **Christian Carbogno**

3. Especialistas en nanotecnología y nuevos materiales para sensores y energía
 Asociados al proyecto **Triboelectric nanogenerator based self-powered sensor for artificial intelligence** (que requiere habilidades como **Materials science**, **Nanotechnology** y **Systems engineering**):

- * **Yuankai Zhou**
- * **Maoliang Shen**
- * **Xin Cui**
- * **Yicheng Shao**
- * **Lijie Li**
- * **Yan Zhang**

Figura 11. El chatbot admite la ausencia de datos exactos y generaliza de forma honesta hacia el perfil más cercano disponible.

En una segunda pregunta hipotética sobre un equipo de IA explicable (XAI) aplicada a diagnóstico médico, el sistema fue un paso más allá: utilizó la relación CITES del grafo para identificar que un proyecto de oncología estaba citado directamente por el trabajo principal de XAI, empleando así la estructura de conexiones del grafo -y no solo la similitud semántica- para fundamentar mejor su recomendación.

```

Respuesta:
Para armar un equipo de alto nivel especializado en Inteligencia Artificial Explicable (XAI) aplicada al diagnóstico médico, basándonos exclusivamente en el grafo proporcionado, deberías contactar a las siguientes personas y considerar los siguientes proyectos y habilidades (*skills*):

### 1. Expertos en Explicabilidad de Modelos de IA (XAI)
Para liderar la transparencia y confiabilidad de los modelos, debes contactar a investigadores de los proyectos pilares de XAI en el grafo:
* Natalia Díaz-Rodríguez, Javier Del Ser y Francisco Herrera: Coautores de los proyectos clave Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI y Explainable Artificial Intelligence (XAI): What we know and what is left to attain Trustworthy Artificial Intelligence.
* Plamen Angelov y Eduardo Soares: Autores del proyecto Explainable artificial intelligence: an analytical review.
* *Skills clave aportados: Computer science, Artificial intelligence, Trustworthiness (confiabilidad) e Interpretability (interpretabilidad).

### 2. Expertos en Salud y Diagnóstico Médico (IA Aplicada)
Para asegurar el conocimiento clínico y la correcta integración de datos de diagnóstico, debes contactar a:
* Faisal Mahmood, Jana Lipková y Richard J. Chen: Investigadores del proyecto Artificial intelligence for multimodal data integration in oncology (enfoque en oncología y diagnóstico de cáncer). Nota: Este proyecto es citado directamente por el trabajo principal de XAI de Barredo Arrieta, Díaz-Rodríguez y Del Ser.
* Reabal Najjar: Autor del proyecto Redefining Radiology: A Review of Artificial Intelligence Integration in Medical Imaging, ideal para la interpretación de imágenes de diagnóstico.
* Robert Challen y Joshua C. Denny: Del proyecto Artificial intelligence, bias and clinical safety, indispensables para asegurar la seguridad del paciente.
* *Skills clave aportados: Medicine, Oncology (oncología), Radiology (radiología), Cancer research y Patient safety (seguridad del paciente).

```

Figura 12. El chatbot combina búsqueda semántica y estructura del grafo (relación CITES) para justificar su recomendación.

4.5.3 Limitaciones observadas: preguntas de agregación global

El sistema mostró una limitación estructural clara ante preguntas que requieren agregación sobre la totalidad del grafo (por ejemplo, "¿qué persona participa en más proyectos?"). Con la configuración por defecto (TOP_K=5), el chatbot solo tiene visibilidad de un vecindario reducido del grafo, por lo que generaliza incorrectamente una conclusión local ("nadie repite proyecto") como si fuera válida para el grafo completo.

```

Pregunta> ¿Qué persona participa en más proyectos?
(nodos relevantes encontrados: ['Measurement Instruments for the Anthropomorphism, Animacy, Likeability, Perceived Safety & Creativity: A Manifesto for Collaboration', 'Artificial Intelligence in Education: A Review', 'Urban Defining Artificial Intelligence'])

Respuesta:
Basándonos únicamente en el contexto proporcionado, ninguna persona participa en más de un proyecto. Todos los investigadores mencionados están vinculados a exactamente un (1) proyecto, por lo que existe un empate general con una sola participación por persona.

A continuación se detallan los investigadores correspondientes a cada proyecto:

1. Proyecto: "Measurement Instruments for the Anthropomorphism, Animacy, Likeability, Perceived Intelligence, and Perceived Safety of Robots" (el cual requiere *skills* como Computer science, Artificial intelligence y Psychology):
* Christoph Bartneck
* Dana Kulić
* Elizabeth A. Croft
* Susana Zoghbi

2. Proyecto: "Artificial Intelligence & Creativity: A Manifesto for Collaboration" (el cual requiere *skills* como Computer science, Artificial intelligence y Creativity):
* Florent Vinchon, Todd Lubart, Sabrina Bartolotta, Valentin Girronnay, Marion Botella, Samira Bourgeois-Bougrine, Jean-Marie Burkhardt, Nathalie Bonnardel, Giovanni Emanuele Corazza, Vlad Petre Glăveanu, Michael Hanchett Hanson, Zorana Ivčević, Maciej Karwowski, James C. Kaufman, Takeshi Okada, Roni Reiter-Palmon y Andrea Gaggioli.

```

Figura 13. Con TOP_K=5, el chatbot concluye erróneamente que ninguna persona participa en más de un proyecto, al ver solo una muestra parcial del grafo.

Es importante notar que esta no es una alucinación en el sentido clásico (el modelo no inventó datos falsos): el razonamiento sobre los 5 proyectos recibidos como contexto fue correcto. El error es de generalización indebida desde una muestra parcial hacia una conclusión global, producto del diseño mismo de la arquitectura RAG.

Al incrementar TOP_K a 150 (esencialmente el total de proyectos del grafo), el sistema sí logró identificar correctamente a las tres personas con mayor participación (3 proyectos cada una), coincidiendo exactamente con la consulta Cypher de referencia (Figura 6).

Este hallazgo evidencia un trade-off central en el diseño de sistemas RAG: un TOP_K reducido es eficiente pero ciego a patrones globales, mientras que un TOP_K elevado recupera precisión a costa de perder la eficiencia que constituye la razón de ser del enfoque RAG frente a simplemente enviar todo el dataset al modelo. En un grafo de la escala que maneja NASA (proyectando más de 500.000 nodos), esta segunda estrategia no sería viable.

Se identificó además una segunda limitación, independiente de TOP_K: la función de expansión de contexto solo recorre un salto de distancia desde cada proyecto relevante. Esto implica que entidades a dos saltos, como Organization (Project → Person → Organization), quedan fuera del contexto sin importar cuán alto sea TOP_K, ya que la limitación no es de cobertura de nodos sino de profundidad de expansión del grafo.

4.5.4 Consultas favorecidas por un contexto amplio

Con TOP_K=150, el sistema demostró buen desempeño identificando patrones que sí están a un salto de distancia, como las relaciones PUBLISHED_IN, CITES y SIMILAR_TO, superando ampliamente a la configuración por defecto:

```
Respuesta:
Basándose en la información del grafo de conocimiento académico provisto, los proyectos se
publicaron en múltiples revistas y conferencias (*venues*).

La revista que aparece **más veces** es **Sustainability**, con un total de **3 publicaciones**. Las
revistas y conferencias que registran más de una aparición son:

* **Sustainability (3 veces):**
  * *The Sustainability of Artificial Intelligence: An Urbanistic Viewpoint from the Lens of
    Smart and Sustainable Cities* (de los autores **Tan Yigitcanlar** y **Federico Cugurullo**, que
    requiere *skills* como *Smart city* y *Urban planning*).
  * *Artificial Intelligence, Transport and the Smart City: Definitions and Dimensions of a New
    Mobility Era* (de **Alexandros Nikitas** y otros).
  * *Artificial Intelligence and Its Role in Education* (de **Sayed Fayaz Ahmad** y otros).
* **AI & Society (2 veces):**
  * *The news framing of artificial intelligence: a critical exploration of how media discourses
    make sense of automation* (de **Dennis Nguyen** y **Erik Hekman**, que requiere la habilidad de
    *Sociology*).
  * *Artificial intelligence, transparency, and public decision-making* (de **Karl de Fine
    Licht** y **Jenny de Fine Licht**).
* **International Journal of Educational Technology in Higher Education (2 veces):**
  * *Artificial intelligence in higher education: the state of the field* (de **Helen Crompton**
    y **Diane Burke**, que requiere la *skill* de *Higher education*).
  * *The impact of artificial intelligence on learner-instructor interaction in online learning*
    (de **Ido Roll** y otros).
* **National Bureau of Economic Research (2 veces):**
  * *The Skill Content of Recent Technological Change: An Empirical Exploration* (de **David
    Autor**, **Frank Levy** y **Richard J. Murnane**, que requiere la habilidad de *Technological
    change*).
  * *The Impact of Artificial Intelligence on Innovation* (de **Iain Cockburn** y otros).
* **International Journal of Human-Computer Interaction (2 veces):**
  * *Towards Responsible AI: A Design Space Exploration of Human-Centered Artificial
    Intelligence User Interfaces to Investigate Fairness* (de **Yuri Nakao** y otros).
  * *Six Human-Centered Artificial Intelligence Grand Challenges* (de **Özlem Özmen Garibay** y
    otros).
* **Electronic Markets (2 veces):**
  * *Artificial intelligence and machine learning* (de **Niklas Kühl** y otros).
  * *Trustworthy artificial intelligence* (de **Scott Thiebes** y otros).
* **Artificial Intelligence Review (2 veces):**
  * *Artificial intelligence in the creative industries: a review* (que requiere habilidades
    como *Deep learning* y *Computational creativity*).
  * *Human activity recognition in artificial intelligence framework: a narrative review* (de
    **Neha Gupta** y otros).

El resto de los proyectos se publicaron una sola vez en otros *venues* como *Journal of Business
Research*, *SNMTE Motion Imaging Journal*, *Science and Engineering Ethics*, *Journal of Product
Innovation Management*, *BMJ Quality & Safety*, *Frontiers in Sustainable Cities*, *PLOS ONE*, entre
otros.
```

Figura 14. Con TOP_K=150, el chatbot identifica correctamente la revista con más publicaciones asociadas (Sustainability, 3 veces), coincidiendo con la consulta Cypher de referencia.

Respuesta:
 Basado únicamente en la información de contexto extraída del grafo de conocimiento, los proyectos que son más similares entre sí (definidos por la relación `SIMILAR\_TO`) se agrupan de la siguiente manera:

```

### 1. Inteligencia Artificial en Ciudades Inteligentes y Sostenibilidad
*   ***"Urban Artificial Intelligence: From Automation to Autonomy in the Smart City"*** es similar a
***"Contributions and Risks of Artificial Intelligence (AI) in Building Smarter Cities: Insights from
a Systematic Review of the Literature"*** (y viceversa).
*   ***"The Sustainability of Artificial Intelligence: An Urbanistic Viewpoint from the Lens of Smart
and Sustainable Cities"*** es similar a:
*   ***"Smarter eco-cities and their leading-edge artificial intelligence of things solutions for
environmental sustainability: A comprehensive systematic review"*** (y viceversa).
*   ***"Contributions and Risks of Artificial Intelligence (AI) in Building Smarter Cities:
Insights from a Systematic Review of the Literature"*** (y viceversa).

### 2. Inteligencia Artificial Explicable (XAI)
*   ***"Explainable Artificial Intelligence (XAI): What we know and what is left to attain
Trustworthy Artificial Intelligence"*** es similar a:
*   ***"A Systematic Review of Explainable Artificial Intelligence in Terms of Different
Application Domains and Tasks"*** (y viceversa).
*   ***"Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and
challenges toward responsible AI"*** (y viceversa).
*   ***"Explainable artificial intelligence: an analytical review"*** es similar a ***"Four principles
of explainable artificial intelligence"***.

### 3. Descubrimiento de Fármacos
*   ***"Artificial Intelligence in Drug Discovery"*** es similar a ***"Artificial intelligence for
natural product drug discovery"*** (y viceversa).

### 4. Desafíos y Ética
*   ***"Six Human-Centered Artificial Intelligence Grand Challenges"*** es similar a ***"Building
Ethics into Artificial Intelligence"***.

```

Figura 15. El chatbot no solo listó los 13 pares de SIMILAR_TO correctamente, sino que los agrupó en clusters temáticos de forma espontánea (ciudades inteligentes, XAI, descubrimiento de fármacos, ética).

5. Discusión y limitaciones metodológicas

5.1 Ruido temático en la búsqueda por texto libre

Al analizar manualmente los 150 títulos recuperados, se determinó que solo aproximadamente 6 papers (4% de la muestra) están genuinamente relacionados con exploración espacial. El resto corresponde a inteligencia artificial aplicada a dominios muy diversos (educación, salud, manufactura, ciudades inteligentes, ética, entre otros), incluidos por coincidencia léxica de la palabra "space" en sentidos no relacionados (design space, chemical space, vector space, materials-space).

```
Pregunta> ¿Qué proyectos abordan la aplicación de inteligencia artificial específicamente en misiones o exploración espacial?
(nodos relevantes encontrados: ['On Defining Artificial Intelligence', 'Artificial Intelligence for a Better Future', 'Artificial General Intell
, and Future Prospects', 'Urban Artificial Intelligence: From Automation to Autonomy in the Smart City', 'Artificial intelligence and corporate in
genda'])

Respuesta:
Basándome únicamente en el contexto proporcionado, **no existe información** sobre proyectos,
personas o habilidades que aborden la aplicación de la inteligencia artificial específicamente en
misiones o exploración espacial.

Los proyectos y temáticas registrados en el grafo de conocimiento se limitan a:
* ***On Defining Artificial Intelligence*** (de Pei Wang), enfocado en la definición, epistemología
y fundamentos de la IA.
* ***Artificial Intelligence for a Better Future*** (de Bernd Carsten Stahl), relacionado con la
gobernanza de la investigación e innovación.
* ***Artificial General Intelligence: Concept, State of the Art, and Future Prospects*** (de Ben
Goertzel), enfocado en la IA general, pruebas de Turing y modelos fundacionales.
* ***Urban Artificial Intelligence: From Automation to Autonomy in the Smart City*** (de Federico
Cugurullo), centrado en aplicaciones urbanas y ciudades inteligentes.
```

Figura 16. Ante una pregunta sobre exploración espacial, el chatbot reconoce honestamente que el contexto recuperado no corresponde al tema solicitado, en lugar de inventar una respuesta.

Este hallazgo es consistente con las limitaciones que el propio equipo de NASA reportó en su presentación respecto a la necesidad de mejorar la calidad y desambiguación de los datos extraídos automáticamente (por ejemplo, mapear "JS" a "JavaScript"). En nuestro caso, el problema análogo sería mapear apariciones de "space" a su sentido correcto según el contexto. Una mejora futura consistiría en filtrar por el campo concepts de OpenAlex en lugar de texto libre, combinando conceptos como "Aerospace engineering" o "Astronautics" junto con "Artificial intelligence".

Cabe destacar un hallazgo positivo dentro de este ruido: los dos papers más claramente relacionados con exploración espacial dentro de la muestra ("The Role of Artificial Intelligence In Space Exploration" y "Using Artificial Intelligence for Space Challenges: A Survey") se citan mutuamente, sugiriendo que, pese al ruido general, el grafo logró capturar al menos una conexión temáticamente correcta.

5.2 Sesgo de conceptos genéricos

Al preguntar "¿qué es lo que más se investiga en este grafo?", el sistema respondió, de forma correcta pero poco informativa, que el tema dominante es la inteligencia artificial. Esto es una consecuencia directa y esperable del sesgo de selección de la muestra (la propia búsqueda fue por ese término), no un error del pipeline. Se documenta como ejemplo de cómo un sistema de recuperación de información puede producir respuestas técnicamente correctas pero de bajo valor informativo cuando el dataset subyacente está sesgado.

5.3 Comparación entre GraphRAG y consultas estructuradas (Cypher)

La experimentación permitió establecer una distinción clara sobre cuándo cada enfoque resulta más adecuado:

Tipo de pregunta	Herramienta recomendada	Motivo
Temática / interpretativa ("¿qué proyectos tratan sobre X?")	GraphRAG	Requiere similitud semántica y síntesis en lenguaje natural
Agregación global ("¿quién participa en más proyectos?")	Cypher directo	Requiere recorrer la totalidad del grafo, no una muestra

Búsqueda de talento con criterios múltiples	GraphRAG	Se beneficia de razonamiento sobre estructura + lenguaje natural
Conteos y rankings exactos	Cypher directo	Cypher garantiza exactitud; el LLM puede generalizar mal

Esta distinción sugiere que una arquitectura de producción robusta debería combinar ambos enfoques (a veces denominado "agentic RAG" o "text-to-Cypher + RAG"), detectando automáticamente el tipo de pregunta y enrutándola hacia la herramienta adecuada -mejora que el propio equipo de NASA identificó como trabajo futuro en su presentación.

6. Conclusiones

El proyecto logró replicar, a escala académica y con datos 100% públicos, los elementos centrales del People Knowledge Graph de NASA: un grafo de conocimiento orientado a nodos en Neo4j, cálculo de similitud semántica entre proyectos, y un chatbot GraphRAG funcional sobre una arquitectura gratuita (OpenAlex + sentence-transformers local + Google Gemini).

Más allá de la implementación técnica, el proyecto permitió identificar de forma empírica las fortalezas y limitaciones reales de un sistema GraphRAG: buen desempeño en preguntas temáticas y de búsqueda de talento con razonamiento sobre estructura de grafo, y limitaciones claras en preguntas de agregación global, cuya causa raíz (visibilidad parcial del grafo mediante búsqueda vectorial local) resulta ilustrativa de un problema de diseño general en sistemas RAG, no exclusivo de esta implementación.

Finalmente, el proceso evidenció la importancia de la calidad de los datos de entrada: un sesgo aparentemente menor en la estrategia de búsqueda (texto libre vs. filtrado por conceptos) tuvo un impacto significativo en la relevancia temática de la muestra final, un aprendizaje metodológico válido más allá del alcance específico de este proyecto.

7. Referencias

- Tasneem, S. (2025). How NASA is Using Graph Technology and LLMs to Build a People Knowledge Graph. Memgraph Blog. <https://memgraph.com/blog/nasa-memgraph-people-knowledge-graph>
- OpenAlex. Índice académico abierto. <https://openalex.org>
- Neo4j Graph Database & Analytics. <https://neo4j.com>
- Reimers, N. & Gurevych, I. Sentence-Transformers (all-MiniLM-L6-v2). <https://www.sbert.net>
- Google AI Studio / Gemini API. <https://aistudio.google.com>